

LAPORAN TUGAS BESAR BIG DATA

*Implementasi Pipeline Big Data ETL dan ELT pada Studi Kasus Analisis Risiko
Gagal Bayar Kartu Kredit Taiwan (2005) dan Kaitannya dengan Lingkungan
Makroekonomi*

Mata Kuliah : Big Data

Topik : Analitik Keuangan dan Transaksi Digital

Program Studi : S1 Teknik Komputer

Fakultas : Teknik Elektro



Disusun oleh

Fajri Hadiid Abdani — NIM 1103223188

Muhammad Sabian Aziz— NIM 1103223236

Dosen Pengampu

Angel Metanosa Afinda, S.Kom., M.Kom.

Tahun Akademik

Genap 2025/2026

ABSTRAK

Risiko gagal bayar (default) kartu kredit merupakan salah satu permasalahan inti dalam analitik keuangan dan transaksi digital. Proyek ini membangun dua pipeline data — ETL dan ELT — untuk menganalisis risiko gagal bayar kartu kredit di Taiwan tahun 2005 dan kaitannya dengan lingkungan makroekonomi. Data primer berupa UCI Default of Credit Card Clients (± 30.000 nasabah, 24 kolom) diperbanyak menggunakan CTGAN menjadi 150.000 nasabah sintetis (rasio default $\pm 22\%$ dipertahankan), kemudian di-unpivot menjadi grain bulanan sehingga menghasilkan 900.000 baris fakta untuk periode April–September 2005. Data makro diperoleh dari FRED API (JSON) berupa nilai tukar dan cadangan devisa Taiwan. Pipeline ETL mentransformasi data baris-per-baris dengan Apache Spark (PySpark) di luar warehouse, sedangkan pipeline ELT memuat data mentah lebih dulu lalu mentransformasinya di dalam Apache Hive menggunakan window function dan agregasi OLAP. Keduanya memuat data ke data warehouse Hive berskema bintang dan divisualisasikan melalui website yang akan menjadi dashboard. Hasil utama: tingkat default keseluruhan 0,2212 dengan perbedaan jelas antar demografi, sementara korelasi default terhadap indikator makro mendekati nol akibat keterbatasan grain label. Secara performa, ELT terukur $\pm 5\times$ lebih cepat daripada ETL untuk beban kerja ini, sedangkan ETL unggul dalam mengelola kualitas data.

Kata kunci: Big Data, ETL, ELT, Data Warehouse, Apache Hive, Apache Spark, CTGAN, Credit Default, Dashboard Analitik.

BAB I. PENDAHULUAN

1.1 Latar Belakang

Domain keuangan dan transaksi digital menghasilkan data dalam volume sangat besar dan dengan kecepatan pertumbuhan yang tinggi. Setiap nasabah kartu kredit menghasilkan jejak transaksi, tagihan, dan pembayaran bulanan, sementara lembaga keuangan harus mengkombinasikannya dengan indikator makroekonomi yang berasal dari sumber dan format yang berbeda. Pada studi kasus ini, data perilaku nasabah (UCI Default of Credit Card Clients) digabungkan dengan data ekonomi makro Taiwan dari FRED. Permasalahan data muncul pada empat dimensi Big Data: volume (ratusan ribu hingga jutaan baris setelah augmentasi dan unpivot), variety (file XLSX/CSV dan API JSON), veracity (adanya nilai hilang, duplikat, dan outlier), serta velocity (kebutuhan memproses ulang data secara berkala dan terotomasi).

Karakteristik data semacam ini sulit ditangani secara efektif dengan pendekatan pengolahan konvensional berbasis spreadsheet atau skrip ad-hoc, karena tidak terstruktur, tidak reproduisibel, dan tidak skalabel. Diperlukan sebuah pipeline pengolahan data yang terstruktur, terotomasi, dan dapat dijalankan ulang. Dalam konteks ini, pendekatan ETL (Extract–Transform–Load) dan ELT (Extract–Load–Transform) menjadi relevan: ETL membersihkan dan merekayasa data sebelum dimuat ke warehouse sehingga cocok untuk data terstruktur dan kebutuhan kualitas tinggi, sedangkan ELT memuat data mentah lebih dulu dan memanfaatkan daya komputasi warehouse untuk transformasi, sehingga lebih fleksibel untuk eksplorasi dan iterasi cepat.

Secara eksplisit, latar belakang ini menjawab: (1) masalah utama adalah mengintegrasikan data perilaku kredit multisumber-multiformat yang tidak konsisten menjadi data warehouse analitik yang siap pakai; (2) data dikategorikan kompleks/berskala besar karena setelah augmentasi CTGAN dan unpivot bulanan menghasilkan 900.000 baris fakta dengan campuran tipe numerik, kategorikal, dan waktu; (3) pipeline Big Data diperlukan agar proses extract, transform, dan load berjalan otomatis, reproduisibel, dan dapat diukur performanya untuk dibandingkan.

1.2 Rumusan Masalah

1. Bagaimana merancang dan mengimplementasikan pipeline ETL dan ELT untuk mengintegrasikan data kartu kredit (file) dan data makroekonomi (API) ke dalam satu data warehouse analitik?
2. Faktor demografis dan perilaku pembayaran apa yang paling berkaitan dengan risiko gagal bayar, dan bagaimana hubungannya dengan indikator makroekonomi Taiwan 2005?
3. Bagaimana perbandingan pendekatan ETL dan ELT dari sisi performa, beban komputasi, kompleksitas implementasi, dan kesesuaian dengan studi kasus ini?

1.3 Tujuan

- Mengimplementasikan pipeline ETL berbasis Python (PySpark) untuk membersihkan, menstandarisasi, merekayasa fitur, dan memuat data ke data warehouse;
- mengimplementasikan pipeline ELT yang memanfaatkan kemampuan transformasi di dalam data warehouse Apache Hive (window function dan agregasi OLAP);

- merancang dan membangun data warehouse dengan skema bintang yang sesuai kebutuhan analitik;

1.4 Ruang Lingkup

Dataset yang digunakan adalah UCI Default of Credit Card Clients (sumber utama, file XLSX/CSV) dan seri makroekonomi Taiwan dari FRED API (sumber pendukung, JSON), keduanya untuk periode tahun 2005. Tools dan teknologi yang dimanfaatkan meliputi Apache Kafka (extract bus), Apache Spark/PySpark (transform ETL), Apache Hive dengan metastore PostgreSQL (data warehouse), SDV CTGAN (augmentasi data sintetis), serta website yang akan menjadi media visualisasi, seluruhnya diorkestrasi dengan Docker Compose.

Batasan sistem: pipeline bersifat batch dan tidak mencakup pemrosesan data real-time maupun streaming kontinu (Kafka digunakan sebagai bus extract batch, bukan analitik streaming); cakupan indikator makro dibatasi pada data yang benar-benar tersedia bulanan di FRED untuk Taiwan 2005 (nilai tukar dan cadangan devisa); serta data nasabah merupakan data sintetis hasil CTGAN sehingga tidak merepresentasikan populasi nyata mana pun secara langsung.

BAB II. DESKRIPSI DATA DAN STUDI KASUS

2.1 Deskripsi Studi Kasus

Studi kasus berada pada domain analitik keuangan dan transaksi digital, khususnya manajemen risiko kredit. Penerbit kartu kredit secara operasional mencatat limit kredit, tagihan bulanan, jumlah pembayaran, dan status keterlambatan setiap nasabah, lalu perlu memprediksi nasabah mana yang berisiko gagal bayar pada bulan berikutnya. Fenomena ini menghasilkan data berukuran besar dan terus bertambah, serta secara logis dipengaruhi oleh kondisi makroekonomi seperti nilai tukar dan cadangan devisa yang mencerminkan tekanan ekonomi.

Tujuan analitik yang ingin dicapai adalah: (1) mengidentifikasi profil nasabah yang cenderung gagal bayar berdasarkan demografi; (2) menemukan pola pembayaran/tagihan yang memprediksi default melalui fitur rekayasa; dan (3) menganalisis keterkaitan risiko default dengan indikator makroekonomi sepanjang April–September 2005. Tujuan ini menuntut integrasi data multisumber, pembersihan dan rekayasa fitur, serta penyimpanan terstruktur dalam data warehouse — yang menjadi alasan langsung perancangan pipeline Big Data ETL dan ELT pada proyek ini.

2.2 Sumber Data


No	Sumber Data	Jenis	Format	Peran
1	UCI Default of Credit Card Clients (id 350)	File	XLSX/CSV	Data utama (perilaku kredit nasabah)
2	FRED — Federal Reserve Economic Data (Taiwan)	API	JSON	Data pendukung (indikator makroekonomi)

Sumber 1 berperan sebagai data utama yang berisi fitur perilaku dan target gagal bayar. Sumber 2 berperan sebagai data pendukung/enrichment yang memberi konteks makroekonomi terhadap perilaku kredit. Penggunaan dua sumber (file + API) dan dua format (XLSX/CSV + JSON) memenuhi sekaligus persyaratan multisumber dan multiformat (bonus).

2.3 Karakteristik Dataset

Tabel berikut merangkum dimensi dataset sebelum dan sesudah preprocessing pada pipeline ETL.

Tahap	Baris	Kolom	Keterangan
UCI mentah (raw)	30.000	25	1 kolom ID + 23 fitur + 1 target
Sintetis CTGAN	150.000	24	augmentasi sebelum merge makro
FRED makro mentah	12 / seri (×4)	4	observasi bulanan 2005 per seri
Fakta setelah unpivot + enrichment	900.000	± 20	grain klien × bulan (Apr–Sep 2005)



Gambar 2.1 Struktur skema bintang & contoh relasi tabel hasil pipeline ETL (fact_credit_monthly + dimensi).

Tipe kolom mencakup: kolom numerik (limit_bal, bill_amt, pay_amt, fitur rekayasa, indikator makro), kolom kategorikal (sex, education, marriage), dan kolom bertipe waktu (date_key/dim_date untuk kalender bulanan 2005). Kolom ID berperan sebagai primary key: id pada dim_client dan date_key pada dim_date; keduanya menjadi foreign key pada fact_credit_monthly sehingga membentuk relasi bintang.

Kualitas data dianalisis secara kritis. Missing value muncul terutama setelah operasi rasio (misalnya pembagian dengan tagihan bernilai nol pada payment_ratio) dan ditangani per tipe data. Data duplikat berpotensi muncul pada kunci id dan ditangani melalui deduplikasi berbasis primary key. Outlier terdeteksi pada nilai tagihan/pembayaran (kredit) dan deret makro; keberadaannya berimplikasi pada distribusi fitur sehingga memerlukan deteksi outlier (IQR untuk kredit, Z-Score untuk makro) serta clamping pada kolom umur. Catatan penting: terdapat 78.323 baris dengan credit_utilization negatif yang merupakan kondisi valid (akun overpaid) dan sengaja dipertahankan, bukan dibuang sebagai error.

2.4 Data Augmentation / Synthetic Data

Bagian ini disertakan karena jumlah data awal (± 30.000 baris) kurang dari 100.000 baris. Metode yang digunakan adalah CTGAN (Conditional Tabular GAN) melalui pustaka SDV (CTGANSynthesizer). Model dilatih dari tabel UCI asli; kolom SEX, EDUCATION, MARRIAGE, dan target dipaksa bertipe kategorikal, sedangkan kolom ID di-drop sebelum pelatihan. Parameter ter-realisasi: rows = 150.000, epochs = 300, seed = 42, dengan conditional sampling menjaga rasio kelas {non-default 0,7788 ; default 0,2212} sesuai distribusi asli.

Alasan pemilihan CTGAN: data kredit bersifat mixed-type (kontinu + kategorikal + ordinal PAY_*) dan imbalanced, sehingga CTGAN lebih baik menangkap distribusi multimodal dibanding Gaussian-copula atau resampling sederhana,

Potensi bias dan keterbatasan: fidelitas data sintetis tidak melebihi sumbernya; berpotensi terjadi correlation drift antar kolom; bias demografi tahun 2005 ikut diperbesar pada skala 150.000 baris; dan secara prinsip data sintetis menambah volume bukan informasi baru sehingga tidak boleh diperlakukan sebagai bukti dunia nyata yang independen.

BAB III. ARSITEKTUR SISTEM

3.1 Desain Arsitektur


Arsitektur sistem dirancang end-to-end dari sumber data hingga dashboard analitik. Data diambil dari dua sumber (file UCI dan FRED API) oleh Kafka producer, dipublikasikan ke topik Kafka, lalu dikonsumsi oleh consumer yang mempersistensikan data mentah ke dua lokasi: folder raw/ untuk jalur ETL dan datalake/ untuk jalur ELT. Pemisahan jalur inilah yang membedakan kedua pendekatan.

Pada jalur ETL, Apache Spark (PySpark) melakukan transformasi baris-per-baris di luar warehouse (cleaning, standarisasi, unpivot ke grain bulanan, rekayasa fitur, dan validasi) sebelum hasilnya dimuat ke data warehouse Hive sebagai skema bintang. Pada jalur ELT, data mentah dimuat lebih dulu ke tabel raw Hive tanpa preprocessing, kemudian ditransformasi langsung di dalam warehouse menggunakan SQL set-based (window function, GROUPING SETS, pivot). Perbedaan keduanya terletak pada urutan proses (Transform sebelum vs sesudah Load) dan pada lokasi beban komputasi (mesin Python/Spark vs mesin SQL warehouse).

Data lake (folder datalake/ dan tabel raw Hive) berfungsi sebagai tempat penyimpanan data mentah multisumber sebagai lapisan penyangga, sedangkan data warehouse Hive berfungsi sebagai penyimpanan data terstruktur yang telah siap dianalisis (tabel fakta + dimensi + tabel KPI). Data lake menjamin keterlacakan dan kemampuan memproses ulang, sementara warehouse menyediakan antarmuka SQL yang dapat langsung dikonsumsi oleh website.

3.2 Diagram Arsitektur

Tugas Besar Big Data — ETL & ELT Architecture (data flow)



Single self-contained web dashboard (HTML/CSS/JS) · ETL/ELT toggle — KPIs · trend · distribution · filters

Deployment: Docker Compose — Kafka · Spark master+worker · Hive metastore + HiveServer2 · Postgres

Gambar 3.1 Diagram arsitektur sistem Big Data — jalur ETL dan ELT dari sumber hingga dashboard.

Diagram di atas menunjukkan komponen utama: sumber data (UCI XLSX/CSV + FRED API JSON), bus extract Kafka, jalur ETL (Spark transform → Hive star schema → Tableau), jalur ELT (load raw → Hive SQL transform → Power BI), serta data lake dan data warehouse sebagai lapisan penyimpanan. Panah menunjukkan arah aliran data. Diagram ini konsisten dengan implementasi nyata yang dibahas pada Bab IV (ETL) dan Bab V (ELT): jalur kiri

merepresentasikan etl_pipeline/, jalur kanan merepresentasikan elt_pipeline/, dan keduanya bertemu di warehouse Hive sebelum divisualisasikan melalui website.

BAB IV. PIPELINE ETL

4.1 Extract

Ekstraksi diimplementasikan pada `etl_pipeline/extract.py`. Sumber 1 (UCI) diunduh sebagai file Excel (.xls) dengan fallback ke pustaka `ucimlrepo`; sumber 2 (FRED) diambil melalui FRED API untuk empat seri bulanan (EXTAUS, RBTWBIS, NBTWBIS, TRESEGTWM194N) dan disimpan sebagai JSON. Seluruh data mentah dipersistensikan apa adanya ke folder `raw/` tanpa cleaning atau transformasi apa pun pada tahap ini. Setiap sumber mencatat log berisi nama sumber, jumlah baris & kolom, ukuran data, durasi eksekusi, dan status.

Tabel 4.1 Log Extract (run sukses, sumber `etl_pipeline/logs/extract.log`).

Sumber	Status	Baris	Kolom	Ukuran	Durasi	File
uci_credit_card_default (id 350)	OK	30.000	25	5.409,5 KB	34,59 s	raw/uci_credit_card.xls
fred:EXTAUS	OK	12	4	2,0 KB	0,59 s	raw/fred_EXT AUS_2005.json
fred:RBTWBIS	OK	12	4	2,0 KB	0,47 s	raw/fred_RBTWBIS_2005.json
fred:NBTWBIS	OK	12	4	1,9 KB	0,66 s	raw/fred_NBTWBIS_2005.json
fred:TRESEGTWM194N	OK	12	4	2,0 KB	0,52 s	raw/fred_TRESEGTWM194N_2005.json

4.2 Transform

4.2.1 Data Cleaning

- **Penghapusan duplikat:** dengan deduplikasi berbasis primary key id (drop duplicates by PK);
- **Strategi missing value:** nilai hilang ditangani per tipe data (numerik vs kategorikal) setelah operasi rasio yang berpotensi menghasilkan NaN/Inf;
- **Standardisasi datetime:** kolom waktu distandardisasi menjadi `date_key` kalender bulanan 2005;
- **Metode outlier:** IQR untuk data kredit dan Z-Score untuk data makro, serta clamping umur ke rentang [18, 100].

Alasan pemilihan metode: IQR dipilih untuk data kredit karena robust terhadap distribusi yang miring (skewed) dan tidak mengasumsikan normalitas — cocok untuk nilai tagihan/pembayaran yang berekor panjang. Z-Score dipilih untuk deret makro yang relatif kontinu dan mendekati normal sehingga deviasi standar menjadi ukuran outlier yang wajar.

4.2.2 Standardisasi Data

- **Penamaan kolom:** seluruh nama kolom diubah menjadi lowercase snake_case;
- **Normalisasi:** minimal dua kolom numerik dinormalisasi dengan min-max, yaitu `exchange_rate_twd_usd`, `real_broad_eer`, dan `total_reserves`;
- **Encoding kategorikal:** kategori SEX/EDUCATION/MARRIAGE di-encode menjadi label terbaca;

- **Konsistensi tipe data:** seluruh kolom ukuran dipaksa konsisten bertipe double.

4.2.3 Data Enrichment & Feature Engineering

Data kredit di-unpivot dari format wide ke grain bulanan (April–September 2005), kemudian di-join dengan data makro melalui date_key. Lima fitur baru dibuat:

Fitur	Definisi	Logika
credit_utilization	bill_amt / limit_bal	rasio pemakaian terhadap limit; makin tinggi → makin berisiko
payment_ratio	pay_amt / bill_amt	porsi tagihan yang dibayar; rendah → indikasi kesulitan bayar
avg_delay_months	rata-rata status PAY_*	rata-rata tingkat keterlambatan historis
num_months_delayed	jumlah status > 0	berapa bulan nasabah terlambat membayar
repayment_gap	total_bill – total_payment	selisih total tagihan dan pembayaran (beban tersisa)

4.2.4 Validasi Kualitas Data

Enam aturan validasi dijalankan;


NO	Aturan	Hasil
1	Uniqueness (id, date_key)	0 pelanggaran — PASS
2	Null check (kunci tidak boleh null)	0 pelanggaran — PASS
3	Range check	PASS — 78.323 utilisasi negatif valid (akun overpaid), dipertahankan
4	Datatype consistency	konsisten (double) — PASS
5	Referential integrity	0 orphan date / 0 orphan client — PASS
6	Distribution (default_rate)	0,2212 sesuai ekspektasi — PASS

Pada aturan range, ditemukan 78.323 baris credit_utilization bernilai negatif. Setelah ditelusuri, ini bukan kesalahan melainkan kondisi akun overpaid (pembayaran melebihi tagihan) yang valid secara bisnis, sehingga diputuskan untuk dipertahankan dan didokumentasikan, bukan diperbaiki/dibuang. Aturan lain tidak menemukan pelanggaran sehingga tidak memerlukan koreksi.

4.3 Load

Data dimuat ke data warehouse Apache Hive (database bigdata_etl) dalam skema bintang. Tabel fakta fact_credit_monthly (900.000 baris, grain klien × bulan) memiliki foreign key ke dim_client (150.000) dan dim_date (12); dim_macro (12) terhubung melalui dim_date. PK/FK didokumentasikan secara informasional dan seluruh tabel disimpan sebagai PARQUET agar terbaca Hive/ODBC.

ETL Warehouse — Star Schema / ERD (bigdata_etl)



Gambar 4.1 ERD / Skema Bintang warehouse ETL (bigdata_etl).

Delapan query SQL analitik dijalankan (warehouse/etl_analytical_queries.sql). Ringkasan tujuan dan hasil tiap query:

	Query (tujuan)	Hasil ringkas & analisis
Q1	Overall default rate	0,2212 — baseline risiko portofolio $\pm 22\%$
Q2	Default per jenis kelamin	perempuan 0,2439 > laki-laki 0,1991
Q3	Default per pendidikan	university 0,2504 tertinggi; others 0,0752 terendah
Q4	Default per status pernikahan	married 0,2661 tertinggi
Q5	Default per kelompok umur	40–49 thn 0,2451 tertinggi; 60+ 0,1568 terendah
Q6	Tren perilaku bulanan	credit_utilization naik 0,306 $\rightarrow$ 0,478 (Apr $\rightarrow$ Sep)
Q7	Default vs makro per bulan	kurs 31,48 $\rightarrow$ 32,92; default rate konstan 0,2212
Q8	Korelasi default $\leftrightarrow$ makro	$\approx 0,0$ (lihat keterbatasan grain, Bab VII/Temuan)

Setiap query dieksekusi pada warehouse Hive dan status serta waktu eksekusinya dicatat pada load log. Query Q1–Q5 menjawab 'siapa yang gagal bayar' (analisis demografis), Q6 menggambarkan tekanan tagihan yang meningkat sepanjang periode, dan Q7–Q8 menguji keterkaitan dengan makro — yang ternyata mendekati nol karena alasan grain yang dijelaskan pada Bab VII.

BAB V. PIPELINE ELT


5.1 Extract & Load

Pada pipeline ELT (`elt_pipeline/extract_load.py`), data mentah dari sumber yang sama dimuat langsung ke warehouse/data lake tanpa preprocessing. Tabel `bigdata_elt.raw_credit` memuat 150.000 baris $\times$ 25 kolom, sedangkan `raw_macro` memuat 48 baris (4 seri $\times$ 12 bulan). Tidak ada unpivot maupun rekayasa fitur pada tahap ini — seluruh transformasi ditunda hingga berada di dalam warehouse. Metadata load (ukuran dan struktur) dicatat pada `elt_pipeline/logs/load_metadata.json`.

5.2 Transform di Warehouse

Transformasi ELT (`elt_pipeline/transform.sql`, dijalankan `run_transform.py`) sepenuhnya berbasis SQL set-based di Apache Hive, sebuah pendekatan yang sengaja dibuat berbeda dari ETL Python agar nilai ELT tidak nol:

- **Cleaning & unpivot via SQL:** LATERAL VIEW `stack(6, ...)` untuk unpivot data ke `elt_fact_monthly` (900.000 baris) — kontras dengan unpivot DataFrame pada ETL;
- **Window functions:** LAG, running AVG, dan RANK menghasilkan `elt_client_trends` (900.000 baris) untuk tren per nasabah;
- **Agregasi OLAP:** GROUPING SETS menghasilkan `elt_default_by_demographic` (17 baris: tiap dimensi + grand total) dalam satu pass;
- **Feature engineering berbasis query:** pivot makro dengan CASE...MAX menghasilkan `elt_macro_monthly` (12), lalu di-join menjadi `elt_default_vs_macro` (6).



Gambar 5.1 Lineage transformasi ELT di dalam Hive (tabel raw $\rightarrow$ tabel analitik).

Perbedaan mendasar dengan ETL: ETL menempatkan beban transformasi pada mesin Python/Spark sebelum load (cocok untuk rekayasa fitur ML), sedangkan ELT memanfaatkan

mesin SQL warehouse setelah load (cocok untuk eksplorasi cepat dan agregasi OLAP). Output keduanya berbeda secara struktur sehingga ELT bukan salinan ETL.

BAB VI. DASHBOARD ANALITIK


6.1 Tools & Koneksi

Dashboard analitik dibangun dengan menggunakan dashboard dengan HTML, CSS, dan JavaScript. Website ini memvisualisasikan keluaran kedua pipeline sekaligus melalui sebuah pemilih (toggle) ETL/ELT: posisi ETL menampilkan tabel KPI dari warehouse bigdata_etl (), sedangkan posisi ELT menampilkan KPI dari bigdata_elt.

6.2 Desain Dashboard

Desain dashboard dibuat identik pada kedua tool dan terbagi menjadi empat zona, mencakup seluruh elemen wajib:

- **KPI utama:** kartu overall default rate (0,2212), jumlah nasabah, dan jumlah baris fakta;
- **Tren waktu:** tren dual-axis credit_utilization dan kurs sepanjang April–September 2005;
- **Distribusi:** bar chart default rate per demografi (sex, education, marriage, age band);
- **Perbandingan:** scatter default-vs-makro dan perbandingan visual antar kelompok;
- **Filter interaktif:** filter dimensi demografi, indikator makro, dan rentang bulan.



Gambar 6.1 Desain dashboard analitik (empat zona: KPI, distribusi demografi, tren waktu, scatter makro).

Insight utama dari dashboard: risiko default tertinggi pada kelompok married, university, perempuan, dan umur 40–49; tekanan tagihan (credit_utilization) meningkat sepanjang periode; sedangkan scatter default-vs-makro mendekati datar yang mengonfirmasi korelasi makro ≈ 0

BAB VII. ANALISIS KOMPARATIF ETL VS ELT

7.1 Tabel Perbandingan ETL dan ELT

Aspek	ETL	ELT
Kompleksitas Implementasi	Lebih tinggi — PySpark, unpivot, fitur, validasi (500 LOC)	Lebih ringkas — SQL set-based di warehouse (274 LOC)
Fleksibilitas Perubahan	Perlu ubah kode Python & jalankan ulang transform	Cukup ubah/iterasi query di warehouse
Skalabilitas	Skala via Spark cluster (compute terpisah)	Skala mengikuti mesin SQL/warehouse Hive
Kemudahan Eksplorasi Data	Terbatas sebelum load; perlu re-run pipeline	Tinggi — data sudah ada, eksplorasi langsung via SQL
Beban Komputasi	Di hulu (Python/Spark) — peak RSS 95,5 MB	Di warehouse — peak RSS 56,9 MB
Konsistensi & Kualitas Data	Tinggi — validasi 6/6 & fitur ML sebelum load	Bergantung disiplin SQL; cleaning menyusul setelah load
Waktu Time-to-Analysis	Lebih lama — 123,94 s (transform 109,05 s)	Lebih cepat — 24,59 s ($\pm 5\times$ lebih cepat)
Kesesuaian dengan Studi Kasus	Cocok saat butuh fitur rekayasa & tata kelola kualitas	Cocok untuk landing cepat + agregasi OLAP eksploratif
Aspek Lain (penyimpanan)	Star schema bersih untuk website	Tabel analitik OLAP untuk website

7.2 Analisis dan Refleksi

terukur $5\times$ lebih cepat karena transformasi set-based dijalankan langsung oleh mesin SQL Hive pada data yang sudah dimuat, dengan jejak memori lebih kecil dan kode lebih ringkas; ini ideal untuk landing data yang cepat dan eksplorasi in-warehouse. Sebaliknya, ETL lebih berat karena melakukan compute Python/Spark sebelum load, namun memberikan kontrol penuh atas pembersihan kualitas yang terdokumentasi sebelum data menyentuh warehouse.

Untuk studi kasus risiko kredit ini, kedua pendekatan saling melengkapi: ETL lebih sesuai ketika tujuan akhirnya adalah pemodelan, sedangkan ELT lebih sesuai untuk pelaporan/agregasi cepat dan eksplorasi ad-hoc. Keterbatasan ETL adalah biaya komputasi dan kompleksitas pemeliharaan kode; keterbatasan ELT adalah ketergantungan pada kapasitas warehouse dan risiko 'data mentah menumpuk'

7.3 Ringkasan Temuan

- ELT $5\times$ lebih cepat (24,59 s vs 123,94 s) dengan memori lebih kecil dan kode lebih ringkas
- ETL unggul dalam rekayasa fitur, validasi kualitas, dan star schema yang bersih;
- pemilihan pendekatan bergantung tujuan: kualitas/fitur (ETL) vs kecepatan/eksplorasi (ELT);

BAB VIII. KESIMPULAN & SARAN

8.1 Kesimpulan

- Pipeline ETL dan ELT berhasil diimplementasikan untuk mengintegrasikan data kartu kredit (file) dan makroekonomi (API) ke dalam data warehouse Hive berskema bintang, reprodusibel melalui Docker Compose.
- Risiko gagal bayar keseluruhan 0,2212; pendorong demografis tertinggi adalah married (0,2661), university (0,2504), perempuan (0,2439), dan umur 40–49 (0,2451); namun korelasi default terhadap indikator makro ≈ 0 akibat label default bersifat per-klien (keterbatasan grain).
- Secara komparatif, ELT $\pm 5\times$ lebih cepat dan lebih ringan, sedangkan ETL unggul dalam kualitas data dan rekayasa fitur — sehingga keduanya saling melengkapi sesuai tujuan analitik.

8.2 Saran

- menggunakan label default yang time-varying agar analisis korelasi makro menjadi bermakna;
- menambah sumber makro non-FRED (mis. DGBAS/CBC Taiwan) untuk indikator bulanan yang lebih kaya;
- mengevaluasi fidelitas data sintetis (SDV evaluate_quality) dan mengurangi correlation drift;
- mengoptimasi pipeline ETL (partisi/persist Spark) dan mengeksplorasi arsitektur hibrida ELT+ETL.

DAFTAR PUSTAKA

- [1] L. Xu, M. Skoularidou, A. Cuesta-Infante, and K. Veeramachaneni, “Modeling Tabular Data using Conditional GAN,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- [2] I.-C. Yeh and C.-H. Lien, “The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients,” *Expert Systems with Applications*, vol. 36, no. 2, pp. 2473–2480, 2009.
- [3] D. Dua and C. Graff, “UCI Machine Learning Repository: Default of Credit Card Clients Data Set,” University of California, Irvine, 2017. [Online]. Available: <https://archive.ics.uci.edu/dataset/350>
- [4] Federal Reserve Bank of St. Louis, “FRED — Federal Reserve Economic Data, Taiwan series,” [Online]. Available: <https://fred.stlouisfed.org/categories/32438>

LAMPIRAN

Lampiran A. Repositori Kode dan Pipeline

Tautan Repositori GitHub: https://github.com/hadiidfajri/Big-Data_Credit-Card_Macroeconomic

Repositori memuat struktur etl_pipeline/, elt_pipeline/, raw/, datalake/, warehouse/, dashboard/, logs/, architecture/, dan README.md sesuai ketentuan deliverable.

Lampiran B. Dataset dan Sumber Data

- Dataset Utama (UCI id 350): <https://archive.ics.uci.edu/dataset/350/default+of+credit+card+clients>
- Sumber Pendukung / API (FRED Taiwan): <https://fred.stlouisfed.org/categories/32438>
- Dataset sintetis hasil CTGAN: https://github.com/hadiidfajri/Big-Data_Credit-Card_Macroeconomic/blob/main/syn

Lampiran C. Diagram Arsitektur Sistem

Tautan Diagram (PDF/PNG): [architecture_diagram.pdf](#) / [architecture_diagram.png](#)

Lampiran D. Skema Data Warehouse dan Query SQL

Skema & query: https://github.com/hadiidfajri/Big-Data_Credit-Card_Macroeconomic/tree/main/warehouse (etl_star_schema.sql, etl_analytical_queries.sql, serta elt_pipeline/transform.sql._

Lampiran E. Dashboard Analitik

Tautan Dashboard: https://htmlpreview.github.io/?https://github.com/hadiidfajri/Big-Data_Credit-Card_Macroeconomic/blob/main/dashboard/web/index.html

Lampiran F. Log Eksekusi dan Metadata Proses

https://github.com/hadiidfajri/Big-Data_Credit-Card_Macroeconomic (transform.log, load.log, elt.log, elt_load.log, elt_transform.log, kpis.log, ctgan.log).