

Dokumentasi ERD / Skema Database


Tugas Besar Big Data · Credit-Card Default (Taiwan 2005)

Penjelasan detail skema dua warehouse: ETL (star schema) & ELT (table lineage).

Proyek memakai **dua warehouse Hive** dengan pendekatan pemodelan berbeda:
bigdata_etl = *star schema* klasik (fakta + dimensi, ber-PK/FK), dibangun pipeline ETL (PySpark). **bigdata_elt** = rantai *tabel analitik turunan* (set-based SQL), dibangun pipeline ELT. Keduanya menyimpan tabel **STORED AS PARQUET** agar terbaca Hive/ODBC.

BAGIAN A — Warehouse ETL: Star Schema (bigdata_etl)

ETL Warehouse — Star Schema / ERD (bigdata_etl)



PK = Primary Key FK = Foreign Key PF = PK & FK | semua tabel STORED AS PARQUET
Tipe data & kolom: warehouse/etl_star_schema.sql | 1:N = satu dimensi -> banyak baris fakta

Grain fakta: satu baris per klien x bulan tagihan (Apr-Sep 2005) → **900.000 baris**
(150.000 klien x 6 bulan). Sumber DDL: `warehouse/etl_star_schema.sql`. Diagram dihasilkan `warehouse/erd_diagram.py`.

A1. fact_credit_monthly (tabel fakta)

Pusat star schema; satu baris per klien per bulan.

Kolom	Tipe	Peran
id	BIGINT	FK → dim_client.id

date_key	INT	FK → dim_date.date_key (yyyymm, mis. 200509)
month, month_name	INT, STRING	atribut bulan
limit_bal	DOUBLE	plafon kredit
pay_status	INT	status keterlambatan bulan itu (PAY_*)
bill_amt, pay_amt	DOUBLE	tagihan & pembayaran bulan itu
credit_utilization	DOUBLE	fitur: bill_amt / limit_bal
payment_ratio	DOUBLE	fitur: pay_amt / bill_amt
exchange_rate_twd_usd, real_broad_eer, nominal_broad_eer, total_reserves	DOUBLE	enrichment makro (di-join via date_key)
default_payment_next_month	INT	label target (0/1)

A2. **dim_client** (dimensi klien) — 150.000 baris

Kolom	Tipe	Peran
id	BIGINT	PK
sex / sex_label	INT / STRING	kode + label terbaca
education / education_label	INT / STRING	kode + label
marriage / marriage_label	INT / STRING	kode + label
age / age_band	INT / STRING	umur + kelompok umur
default_payment_next_month	INT	label (level klien)
avg_delay_months	DOUBLE	fitur: rata-rata PAY_*
num_months_delayed	INT	fitur: jumlah bulan delay (>0)
total_bill_amt, total_pay_amt	DOUBLE	total tagihan & bayar
repayment_gap	DOUBLE	fitur: total_bill – total_pay

A3. **dim_date** (dimensi tanggal) — 12 baris (2005)

Kolom	Tipe	Peran
date_key	INT	PK (yyyymm)
full_date	DATE	tanggal awal bulan
year, month, month_name, quarter	INT/STRING	atribut kalender
is_billing_month	BOOLEAN	TRUE untuk Apr–Sep 2005

Peran kunci: dim_date menjadi **jembatan** antara data kredit dan data makro — keduanya terhubung lewat date_key.

A4. `dim_macro` (dimensi makro) — 12 baris

Kolom	Tipe	Peran
<code>date_key</code>	INT	PK & FK → <code>dim_date</code>
<code>exchange_rate_twd_usd</code>	DOUBLE	FRED EXTAUS
<code>real_broad_eer</code>	DOUBLE	FRED RBTWBIS
<code>nominal_broad_eer</code>	DOUBLE	FRED NBTWBIS
<code>total_reserves</code>	DOUBLE	FRED TRESEGTWM194N
<code>*_norm</code> (3 kolom)	DOUBLE	versi min-max ternormalisasi


A5. Relasi & kunci (PK/FK)

- `dim_client (id) 1:N fact_credit_monthly (id)`
- `dim_date (date_key) 1:N fact_credit_monthly (date_key)`
- `dim_date (date_key) 1:1 dim_macro (date_key)` → makro nempel ke fakta lewat `date_key`.
- Di Hive, constraint PK/FK bersifat **informasional** (`DISABLE NOVALIDATE RELY`) — didokumentasikan di `etl_star_schema.sql`, divalidasi logis oleh aturan *referential integrity* di `transform.py`.

Kenapa star schema? mudah dipahami, query agregasi cepat, ramah BI tool (Tableau), dan memisahkan ukuran (fakta) dari konteks (dimensi).

BAGIAN B — Warehouse ELT: Table Lineage (`bigdata_elt`)

ELT Warehouse — Table Lineage (`bigdata_elt`) · set-based SQL



ELT **bukan** star schema, melainkan **rantai tabel turunan** yang dibangun murni SQL set-based (kontras dengan ETL). Sumber: `elt_pipeline/transform.sql` + `warehouse/dashboard_kpis.sql`.

B1. Tabel RAW (apa adanya, dari `extract_load.py`)

Tabel	Bentuk	Kolom utama
raw_credit	150.000 × 25	id, limit_bal, sex, education, marriage, age, pay_0, pay_2..6, bill_amt1..6, pay_amt1..6, default_payment_next_month
raw_macro	48 baris (long)	series_id, obs_date, value

B2. Tabel turunan (teknik SQL pada tiap langkah)

Tabel	Baris	Dibuat dari	Teknik SQL
elt_macro_monthly	12	raw_macro	CASE pivot + GROUP BY (long → wide)
elt_fact_monthly	900.000	raw_credit	LATERAL VIEW stack(6, ...) (unpivot 6 bulan di SQL)
elt_client_trends	900.000	elt_fact_monthly	WINDOW: LAG, running AVG, RANK
elt_default_by_demographic	17	raw_credit	OLAP GROUPING SETS (per dimensi + grand total)
elt_default_vs_macro	6	elt_fact_monthly ■ elt_macro_monthly	LEFT JOIN + GROUP BY per bulan

Kolom kunci tabel turunan

- elt_macro_monthly: date_key, exchange_rate_twd_usd, real_broad_eer, nominal_broad_eer, total_reserves.
- elt_fact_monthly: id, date_key, limit_bal, pay_status, bill_amt, pay_amt, default_payment_next_month, credit_utilization, payment_ratio.
- elt_client_trends: id, date_key, bill_amt, pay_amt, credit_utilization, prev_bill_amt, bill_mom_change, run_avg_utilization, bill_rank_in_month.
- elt_default_by_demographic: sex_label, education_label, marriage_label, age_band, clients, default_rate.
- elt_default_vs_macro: date_key, default_rate, exchange_rate_twd_usd, real_broad_eer, total_reserves.

B3. Tabel KPI (materialisasi, `dashboard_kpis.sql`)

Dibuat **identik** di `bigdata_etl` (sumber Tableau) dan `bigdata_elt` (sumber Power BI):
`kpi_overall`, `kpi_default_by_demographic`, `kpi_monthly_default_vs_macro`, `kpi_corr_default_macro`.

Kenapa lineage, bukan star? ELT memperlihatkan kekuatan transform **di dalam** warehouse: unpivot, window function, dan agregasi OLAP langsung di SQL — tabel-tabel ini *flat/denormalised* yang dioptimalkan untuk analitik & dashboard, bukan untuk integritas relasional.

BAGIAN C — Kontras Pemodelan ETL vs ELT

Aspek	ETL (<code>bigdata_etl</code>)	ELT (<code>bigdata_elt</code>)
Pemodelan	Star schema (fakta + dimensi)	Rantai tabel turunan (flat)

Kunci	PK/FK eksplisit (informasional)	Tanpa PK/FK; relasi lewat <code>date_key/id</code> di query
Lokasi transform	Sebelum load (PySpark)	Di dalam warehouse (SQL)
Teknik khas	clean, IQR/Z, unpivot union, fitur ML	CASE pivot, <code>stack()</code> , WINDOW, <code>GROUPING SETS</code>
Cocok untuk	pemodelan & tata kelola	landing cepat + eksplorasi analitik

Cara regenerasi gambar

```
python warehouse/erd_diagram.py # -> warehouse/erd_star_schema.png (+ .pdf) python
warehouse/elt_lineage_diagram.py# -> warehouse/elt_lineage.png (+ .pdf)
```

File DDL/sumber: `warehouse/etl_star_schema.sql`, `elt_pipeline/transform.sql`,
`warehouse/dashboard_kpis.sql`.