

Tugas Besar Big Data — ETL & ELT Pipeline + Analytics Dashboard

Credit-Card Default Risk in Taiwan (2005) vs the Macroeconomic Environment

Anggota Kelompok (Group of 2): [isi nama / NIM anggota 1], [isi nama / NIM anggota 2] · Topic No. 7 — Analitik Keuangan dan Transaksi Digital · Semester: GENAP 2025/2026.

1. Abstract

Proyek ini membangun dua pipeline data (ETL dan ELT) untuk menganalisis risiko gagal bayar kartu kredit di Taiwan (2005) dan kaitannya dengan lingkungan makroekonomi (seri FRED Taiwan). Data primer (UCI *Default of Credit Card Clients*, ~30.000 nasabah) diperbanyak dengan CTGAN menjadi 150.000 nasabah sintetis (rasio default ~22% dipertahankan), lalu di-unpivot menjadi grain bulanan sehingga menghasilkan 900.000 baris fakta (Apr–Sep 2005). Pipeline ETL (PySpark, transform di luar warehouse) dan ELT (SQL window/OLAP di dalam Hive) memuat data ke data warehouse Hive (star schema), lalu divisualisasikan dengan Tableau (ETL) dan Power BI (ELT) melalui Hive ODBC. Temuan utama: tingkat default keseluruhan 0,2212, dengan perbedaan jelas antar demografi (jenis kelamin, pendidikan, status pernikahan, kelompok umur), namun korelasi default terhadap indikator makro ≈ 0 karena keterbatasan grain label (dijelaskan di §10). Perbandingan menunjukkan ELT ~5× lebih cepat daripada ETL untuk beban kerja ini, sedangkan ETL unggul dalam feature engineering dan kualitas pemodelan.

2. Introduction & Problem Statement


- Latar belakang:** risiko gagal bayar kartu kredit adalah masalah keuangan inti; perilaku pembayaran/tagihan nasabah diduga berhubungan dengan kondisi makroekonomi.
- Pertanyaan analitik:** (1) siapa yang cenderung gagal bayar? (2) pola pembayaran/tagihan apa yang memprediksi default? (3) bagaimana risiko default berhubungan dengan kurs / nilai tukar efektif / cadangan devisa Taiwan sepanjang Apr–Sep 2005?
- Tujuan & ruang lingkup:** membangun ETL + ELT yang dapat direproduksi, sebuah data warehouse analitik, dan dashboard interaktif; serta membandingkan kedua pendekatan pipeline secara empiris.

3. Datasets (brief §4)

- Sumber 1 (Primer):** UCI *Default of Credit Card Clients* (id 350), format XLSX/CSV, ~30.000 baris × 24 kolom (23 fitur + 1 target default payment next month); riwayat tagihan Apr–Sep 2005. Link: <https://archive.ics.uci.edu/dataset/350/default+of+credit+card+clients>
- Sumber 2 (Sekunder):** FRED Taiwan macro via FRED API (JSON) — seri EXTAUS, RBTWBIS, NBTWBIS, TRESEGTWM194N (bulanan, 2005). Link kategori: <https://fred.stlouisfed.org/categories/32438>
- Temuan jujur:** FRED tidak menyediakan suku bunga/CPI/pengangguran bulanan untuk Taiwan 2005 → cakupan makro dibatasi pada kurs + cadangan devisa. Indikator lain hanya tahunan/kuartalan (konstan di grain bulanan → tidak berguna).
- Multi-source** ■ (UCI + FRED) · **multi-format** ■ (XLSX/CSV + JSON, bonus).

4. Architecture (CLAUDE.md §5)

Tugas Besar Big Data — ETL & ELT Architecture (data flow)



Same dashboard design built in both tools (KPIs · trend · distribution · filters)

Deployment: Docker Compose — Kafka · Spark master+worker · Hive metastore + HiveServer2 · Postgres

- **Tech stack:** Apache **Kafka** (KRaft) untuk extract bus; Apache **Spark** (master+worker, local[*]) untuk transform ETL; Apache **Hive** (metastore + HiveServer2, backing **Postgres**) sebagai warehouse; **Tableau + Power BI** via **Hive ODBC**; seluruhnya di **Docker Compose**.
- **Alasan pemilihan:** Kafka memisahkan extract dari pemrosesan (dapat di-stream/idempoten); Spark menangani transform baris-per-baris berskala besar; Hive menyediakan warehouse SQL yang dapat diakses ODBC oleh kedua BI tool; Docker Compose membuat seluruh stack reproduisibel sekali jalan.

5. Synthetic Augmentation — CTGAN (method / rationale / bias)

- Metode:** SDV CTGANSynthesizer. Dilatih dari tabel UCI asli (~30.000 baris); SEX, EDUCATION, MARRIAGE, dan target dipaksa **kategorikal**; ID di-drop sebelum training. **Conditional sampling** menjaga rasio kelas. **Parameter ter-realisasi** (synthetic/ctgan_summary.json): **rows = 150.000**, **epochs = 300**, **seed = 42**, balance = *preserve_original* → {non-default 0,7788 ; default 0,2212}, real_rows = 30.000.
- Rationale:** fitur kredit *mixed-type* (kontinu + kategorikal + ordinal PAY_*); CTGAN menangani data tabular multimodal/imbalanced lebih baik daripada Gaussian-copula/resampling, dan *conditional sampler* memberi kontrol eksplisit atas kelas default. Menambah volume tanpa mengumpulkan PII baru.
- Bias & keterbatasan** (ringkas dari synthetic/CTGAN_METHOD.md §3): fidelitas ≤ sumber; potensi *correlation drift* antar kolom; bias demografi 2005 ikut diperbesar di skala 150k; data sintetis menambah volume **bukan informasi** → tidak boleh dianggap bukti dunia nyata independen.

6. Part I — ETL Pipeline (weight 30%)

6.1 Extract — etl_pipeline/extract.py

- Dua sumber diunduh **apa adanya** ke raw/ (tanpa cleaning); tiap sumber mencatat log (rows, cols, size, duration) ke etl_pipeline/logs/. Varian streaming: kafka_producer.py / kafka_consumer.py (sumber → topik Kafka → raw/ + data lake/).
- Hasil: raw/uci_credit_card.xls (30.000×25) + raw/fred_<id>_2005.json ×4 (12 observasi/seri).

6.2 Transform — etl_pipeline/transform.py (PySpark)


- (a) Cleaning:** dedup PK id; missing per-dtype; standardisasi tanggal; outlier **IQR** (kredit)
- Z-score** (makro); clamp age∈[18,100].
- (b) Standardisasi:** kolom → snake_case; **min-max normalise** exchange_rate_twd_usd, real_broad_eer, total_reserves; encode kategori (label terbaca); enforce dtype.
- (c) Enrichment:** **unpivot wide**→**bulanan** (Apr–Sep 2005); join makro via date_key; **5 fitur:** credit_utilization, payment_ratio, avg_delay_months, num_months_delayed, repayment_gap.
- (d) Validation — 6/6 PASS** (warehouse/staging/validation_report.json):

Rule	Hasil
uniqueness (id, date_key)	0 pelanggaran ■
not-null keys	0 pelanggaran ■
range checks	0 pelanggaran ■ (78.323 utilisasi negatif valid — akun overpaid, sengaja dipertahankan)
dtype consistency	konsisten (double) ■
referential integrity	0 orphan date / 0 orphan client ■
distribution default_rate	0,2212 ■

- Output staging:** fact_credit_monthly **900.000** baris, dim_client 150.000, dim_date 12, dim_macro 12.

6.3 Load — etl_pipeline/load.py + Star Schema

ETL Warehouse — Star Schema / ERD (bigdata_etl)



PK = Primary Key FK = Foreign Key PF = PK & FK | semua tabel STORED AS PARQUET

Tipe data & kolom: warehouse/etl_star_schema.sql | 1:N = satu dimensi -> banyak baris fakta

- Star schema bigdata_etl: fact_credit_monthly (FK→dim_client, dim_date) + dim_client, dim_date, dim_macro. PK/FK didokumentasikan (DISABLE NOVALIDATE RELY, informasional).
- 8 query analitik (warehouse/etl_analytical_queries.sql):

#	Query	Hasil ringkas
Q1	overall default	0,2212
Q2	per jenis kelamin	perempuan 0,2439 > laki-laki 0,1991
Q3	per pendidikan	university 0,2504 tertinggi; others 0,0752 terendah
Q4	per status nikah	married 0,2661 tertinggi
Q5	per kelompok umur	40–49 0,2451 tertinggi; 60+ 0,1568 terendah
Q6	tren bulanan	credit_utilization naik 0,306 → 0,478 (Apr→Sep)
Q7	default vs makro/bulan	kurs 31,48 → 32,92; default rate konstan 0,2212
Q8	korelasi default↔makro	≈ 0,0 (lihat \$10)

7. Part II — ELT Pipeline (weight 30%)

- Extract + Load:** elt_pipeline/extract_load.py memuat sumber apa adanya ke Hive bigdata_elt.raw_credit (150.000×25) & raw_macro (48 baris = 4 seri × 12 bulan). Tanpa unpivot/fitur. Metadata: elt_pipeline/logs/load_metadata.json.
- Transform in-warehouse** (elt_pipeline/transform.sql, dijalankan run_transform.py) — murni SQL set-based, **kontras** dengan ETL Python:
- LATERAL VIEW stack(6, ...)** → unpivot ke elt_fact_monthly (900.000 baris).

- **Window functions** (LAG, running AVG, RANK) → `elt_client_trends` (900.000).
- **OLAP GROUPING SETS** → `elt_default_by_demographic` (17 baris: per dimensi + grand total).
- Pivot makro (CASE...MAX) → `elt_macro_monthly` (12); join → `elt_default_vs_macro` (6).

8. Part III — Dashboards (weight 25%)

- Desain **sama** di **Tableau** (→ `bigdata_etl`) & **Power BI** (→ `bigdata_elt`) atas tabel `kpi_*` via Hive ODBC. Spesifikasi: `dashboard/DASHBOARD_SPEC.md`; langkah membangun: `dashboard/DASHBOARD_BUILD_GUIDE.md`.
- **KPI**: overall default rate; default per demografi (sex/education/marriage/age_band); korelasi default↔makro.
- **4 zona**: (A) kartu KPI, (B) bar per-demografi, (C) tren dual-axis Apr–Sep 2005, (D) scatter default-vs-makro. **Filter interaktif**: dimensi demografi, indikator makro, rentang bulan.
- Screenshot di `dashboard/screenshots/` (lihat daftar nama file di `screenshots/README.md`).

9. ETL vs ELT — Comparative Analysis (weight 15%)

Angka terukur (`analysis/etl_vs_elt_metrics.md`, instrumentasi `common/metrics.py`):

Pipeline	Total runtime	Peak RSS	Code LOC
ETL	123,94 s	95,5 MB	500
ELT	24,59 s	56,9 MB	274

- ETL transform (PySpark, 900.000 baris) = **109,05 s**; CTGAN (sekali, pra-step) = 1.793 s/150k.
- **Interpretasi**: ELT ~5× lebih cepat karena transform set-based dijalankan mesin SQL Hive langsung pada data yang sudah dimuat; ETL lebih berat di hulu (compute Python/Spark sebelum load) tetapi menghasilkan *star schema* bersih + fitur ML dan validasi. **ETL** cocok saat butuh fitur rekayasa & tata kelola; **ELT** cocok untuk *landing* cepat + eksplorasi in-warehouse yang murah diiterasi. Diskusi lengkap: `analysis/ETL_vs_ELt_comparison.md`. Bonus: bandingkan screenshot Tableau vs Power BI sebagai bukti visual (angka KPI harus cocok).

10. Key Findings

- **Tingkat default keseluruhan 0,2212** (≈22%).
- **Pendorong demografis terkuat**: married (0,2661), university (0,2504), perempuan (0,2439), umur 40–49 (0,2451) memiliki risiko tertinggi pada masing-masing dimensi.
- **credit_utilization naik** sepanjang Apr→Sep 2005 (0,306→0,478) — tekanan tagihan meningkat.
- **Korelasi default↔makro ≈ 0**: label `default_payment_next_month` bersifat **per-klien** dan didenormalisasi ke 6 baris bulanan → variasi default antar bulan **not** → korelasi dengan makro (yang bervariasi per bulan) = 0. Ini **keterbatasan grain**, bukan temuan ekonomi; analisis makro yang bermakna butuh label default yang *time-varying*.
- **Caveat data sintetis**: hasil tidak mewakili populasi nyata mana pun (lihat §5).

11. Dataset Spec Compliance Checklist (brief §4)

- [x] ≥100.000 baris — **900.000** baris fakta (150k × 6 bulan)
- [x] ≥12 kolom — 24 kredit + 5 fitur rekayasa + 4 kolom makro
- [x] ≥2 sumber — UCI + FRED API
- [x] ≥2 format — XLSX/CSV + JSON (bonus)
- [x] numerik + kategorikal + datetime
- [x] missing values ada & ditangani
- [x] duplikat ada & ditangani (dedup PK)
- [x] ≥1 kolom ID sebagai PK/FK (`id`, `date_key`)
- [x] metode sintetis terdokumentasi (§5 + `synthetic/CTGAN_METHOD.md`)

12. Design Decisions & Rationale (brief §11)

Keputusan	Pilihan	Alasan
Warehouse	Hive	SQL warehouse open-source, dapat diakses ODBC oleh Tableau & Power BI
Fact grain	client × bulan (unpivot)	linkage makro lebih kaya, memenuhi ≥100k baris
Outliers	IQR (kredit) / Z-score (makro)	IQR robust untuk distribusi miring; Z-score untuk deret kontinu
Set makro	FX + reserves (tanpa suku bunga)	keterbatasan cakupan bulanan FRED untuk Taiwan
Sintetis	CTGAN, conditional balance	tabular mixed-type + kontrol kelas target
Pembagian ETL/ELT	fitur Python vs window/OLAP SQL	kontras metodologis yang genuine
Penyimpanan tabel	PARQUET	terbaca Hive/ODBC, kolumnar efisien

13. Reproducibility & Run Order

- Prasyarat: Docker Desktop, .env (FRED key). `docker compose build && docker compose up -d`.
- Urutan: extract → (sekali) CTGAN → ETL transform → ETL load → ELT extract_load → dashboard KPIs → comparison → diagram. Perintah lengkap di README.md & docs/CARA_MENJALANKAN.pdf.
- requirements.txt ter-pin; CTGAN ber-seed (42). **Hardware yang dipakai:** [isi spesifikasi mesin].

14. Conclusion & Limitations

Proyek berhasil membangun ETL + ELT yang reproduibel, warehouse Hive berskema bintang, dan dashboard ganda. Keterbatasan utama: (1) data sintetis tidak mewakili populasi nyata; (2) cakupan makro FRED Taiwan terbatas pada FX + cadangan; (3) korelasi default↔makro nol akibat grain label. Pengembangan lanjut: label default time-varying, sumber makro non-FRED (DGBAS/CBC), dan evaluasi fidelitas CTGAN (evaluate_quality).

15. References

- UCI ML Repository id 350 — Default of Credit Card Clients.
- FRED (Federal Reserve Economic Data) — seri Taiwan EXTAUS, RBTWBIS, NBTWBIS, TRESEGTWM194N.
- SDV / CTGAN (Xu et al., 2019, Modeling Tabular Data using Conditional GAN).
- Apache Kafka, Apache Spark, Apache Hive — dokumentasi resmi.

Cara membuat report.pdf: jalankan `python report/build_report_pdf.py` (render via xhtml2pdf, menaruh report.pdf di root). Gambar `architecture_diagram.png` & `warehouse/erd_star_schema.png` ikut tertanam.